

Especificación matemática y auditoría de implementación del pipeline Complex GMP–PN-IQ-GMP–Sparse PNNN

Documento interno previo a la redacción del paper

Commit 675687dc9b5a4b5c603a533f8b39ef5a53413eac

Índice

1. Objetivo y alcance	3
2. Arquitectura del repositorio	3
3. Configuración canónica	3
4. Entrada, mapeo y eliminación de DC	3
5. Identificación, train interno, validation y señal completa	4
5.1. Selector de identificación	4
5.2. Split interno equilibrado en amplitud	4
5.3. Dominio de evaluación	4
6. Población GMP	4
6.1. Representación genérica del objeto Regressor	4
6.2. Familias GMP inicializadas	4
6.3. Indexado	4
7. Selección DOMP	5
7.1. Entrada y salida	5
7.2. Recurrencia	5
7.3. Aclaraciones esenciales	5
8. Complex GMP-DOMP	5
8.1. Ruta interna	5
8.2. Normalización y lambda	5
8.3. Refit final	6
8.4. Parámetros	6
9. Modelo PN-IQ-GMP propuesto	6
9.1. Normalización de fase	6
9.2. Diccionario I/Q	6
9.3. Selección	6
9.4. Ajuste independiente	6
9.5. Libertad adicional	7
9.6. Contabilidad	7
10.Fixed Ridge	7
11.Dataset PNNN	7
11.1. Características	7
11.2. Redundancias explícitas	7
12.Arquitectura y entrenamiento PNNN	8
12.1. Normalización	8
12.2. Red	8
12.3. Selección de épocas	8
12.4. Refit	8

13.Pruning PNNN	8
13.1. Máscara	8
13.2. Selección de fine-tuning	8
13.3. Refit sparse	8
14.Predicción PNNN	9
15.Métrica NMSE	9
16.Complejidad	9
16.1. Convención	9
16.2. Lineales	9
16.3. PNNN	9
17.Rango de coeficientes	9
17.1. Construcción lineal equivalente	9
17.2. PNNN	10
18.Selección del punto operativo	10
19.Espectros y figuras temporales	10
19.1. Welch	10
19.2. Tiempo	10
20.Widely-linear GMP auxiliar	11
21.Resultados auditados en 340 parámetros	11
22.Checkpoints y reproducibilidad	11
23.Hallazgos y acciones	11
23.1. Crítico: clear dentro del main	11
23.2. Nombre del método	12
23.3. Limitaciones que deben declararse	12
24.Preguntas de defensa y respuestas	12
A. Mapa código–concepto	13
B. Glosario de nombres recomendado	13

1. Objetivo y alcance

Este documento describe, en orden de ejecución y con correspondencia entre código y matemáticas, el pipeline científico canónico del repositorio `PNNN_PNGMP_DOMP_fair_comparison`. Su finalidad es que los autores puedan justificar cada decisión durante la redacción y la defensa del trabajo.

La auditoría cubre el código propio invocado por `main_sweep_and_comparison.m`, la generación de resultados, el experimento widely-linear auxiliar y las pruebas directamente relacionadas. El submódulo externo `third_party/matlab2tikz` se trata como dependencia y no se audita línea por línea. Los ficheros MAT binarios se consideran artefactos de entrada o checkpoint; se auditan sus contratos de uso.

2. Arquitectura del repositorio

El punto de entrada es `main_sweep_and_comparison.m`. La ejecución canónica se organiza en:

1. configuración central en `config/getFairDOMPComparisonConfig.m`;
2. carga, preprocesado y split común;
3. barrido Complex GMP y PN-IQ-GMP;
4. referencias Fixed Ridge;
5. entrenamiento denso y pruning PNNN;
6. selección del punto operativo;
7. evaluación detallada y exportación de figuras.

El código externo de `matlab2tikz` se incorpora mediante submódulo. Los MAT se gestionan mediante Git LFS.

3. Configuración canónica

La configuración principal fija:

- mapeo local `xy_forward`;
- identificación: 10 % de la señal;
- train interno: 85 % de identificación;
- 10 bins internos de amplitud;
- $Q_p^{\text{máx}} = Q_n^{\text{máx}} = 50$, $P_{\text{máx}} = 13$;
- rejilla $\lambda = \{0, 10^{-6}, 10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}\}$;
- presupuestos $P = 20, 30, \dots, 500$;
- PNNN: $M = 13$, órdenes $\{1, 3, 5, 7\}$, modo full y $H = 12$;
- punto de selección: ventana de 100 parámetros y tolerancia de 0.20 dB.

Fuente: `config/getFairDOMPComparisonConfig.m`.

4. Entrada, mapeo y eliminación de DC

El fichero de medida aporta dos señales complejas x e y . Con `xy_forward`:

$$x_{\text{in}} = x, \quad y_{\text{out}} = y.$$

El comentario del código indica que son variables locales del bloque modelado; el nombre no debe reinterpretarse automáticamente como dirección física del PA.

Antes de construir el split se elimina la media de toda la señal:

$$x \leftarrow x - \frac{1}{N} \sum_n x[n], \quad y \leftarrow y - \frac{1}{N} \sum_n y[n].$$

Fuentes: `toolbox/pn_gmp_comparison/selectXYByMapping.m` y `run_parameter_sweep.m`.

5. Identificación, train interno, validation y señal completa

5.1. Selector de identificación

La función `sel_indices` localiza:

$$n_{\text{máx}} = \arg \max_n |y[n]|$$

y escoge un bloque contiguo de longitud aproximada $0.1N$ alineado con segmentos de ese tamaño y que contiene el máximo. La identificación no es una muestra aleatoria de todo el registro.

5.2. Split interno equilibrado en amplitud

Sea $\mathcal{I}$ la identificación. Se ordena $\mathcal{I}$ por $|y[n]|$, se divide en diez bins y se asigna dentro de cada bin el 85 % a train y el resto a validation usando una semilla fija.

5.3. Dominio de evaluación

$$\mathcal{F} = \{1, \dots, N\}.$$

Como $\mathcal{I} \subset \mathcal{F}$, la señal completa no es un holdout independiente. Debe llamarse full-signal evaluation, no independent test.

Fuente: `toolbox/splits/buildCommonComparisonSplit.m`.

6. Población GMP

6.1. Representación genérica del objeto Regressor

Cada columna se representa mediante tres multisets de retardos:

$$\mathcal{X}_k, \quad \mathcal{X}_k^*, \quad \mathcal{E}_k.$$

La columna es:

$$u_k[n] = \prod_{q \in \mathcal{X}_k} x[n-q] \prod_{q \in \mathcal{X}_k^*} x^*[n-q] \prod_{q \in \mathcal{E}_k} |x[n-q]|.$$

Las repeticiones de un mismo retardo implementan potencias. El método `deriveEnvelopeTerms` convierte pares $x[n-q]x^*[n-q]$ en $|x[n-q]|^2$.

6.2. Familias GMP inicializadas

Con $P_{\text{GMP}} = 13$, $L = 10$ y $M = 2$:

$$u_{k,\ell}^{(a)}[n] = x[n-\ell]|x[n-\ell]|^k, \quad k = 0, \dots, 12, \ell = 0, \dots, 10,$$

$$u_{k,\ell,m}^{(b)}[n] = x[n-\ell]|x[n-\ell-m]|^k, \quad k = 1, \dots, 12, m = 1, 2,$$

$$u_{k,\ell,m}^{(c)}[n] = x[n-\ell]|x[n-\ell+m]|^k.$$

El código incluye todos los grados totales del 1 al 13. Después se añaden provisionalmente $x[n]$, $x^*[n]$ y $|x[n]|$ y se eliminan duplicados. El tamaño esperado es 673 columnas: 671 GMP canónicas y dos auxiliares no duplicados.

6.3. Indexado

La construcción usada por el sweep aplica extensión periódica:

$$x[n-q] = x[(n-q-1) \bmod N + 1].$$

Fuente: `toolbox/pn_gmp_comparison/regressorManager.m`, `Regressor.m`, `modelsConfig.m` y `buildGMPRegressorRows.m`.

7. Selección DOMP

7.1. Entrada y salida

`selectDOMPSupport(X,y,K,τ)` recibe una matriz candidata X , un objetivo real o complejo y , el máximo de componentes y una tolerancia de columna.

7.2. Recurrencia

Inicialmente:

$$Z_0 = X, \quad r_0 = y, \quad \mathcal{S}_0 = \emptyset.$$

En la iteración t , para las columnas elegibles:

$$\bar{z}_j = \frac{z_j}{\|z_j\|_2}, \quad s_j = \|\bar{z}_j^H r_{t-1}\|_2.$$

Se selecciona:

$$j_t = \arg \max_j s_j.$$

Con $q = \bar{z}_{j_t}$, se actualiza:

$$Z_t = Z_{t-1} - q(q^H Z_{t-1}).$$

Después se ignora la matriz ortogonalizada para el ajuste y se resuelve sobre las columnas originales:

$$\hat{c}_t = \arg \min_c \|y - X_{\mathcal{S}_t} c\|_2^2, \quad r_t = y - X_{\mathcal{S}_t} \hat{c}_t.$$

El solver usa QR cuando el rango se considera completo y `lsqminnorm` en caso contrario.

7.3. Aclaraciones esenciales

- DOMP selecciona *columnas*, no “coeficientes”.
- Ridge no participa en la selección del soporte.
- Complex GMP y PN-IQ tienen rutas DOMP distintas.
- Cada ruta máxima se calcula una vez y los presupuestos usan prefijos.
- En PN-IQ, X es real y y complejo; el módulo de la correlación combina ambas componentes de salida.

Fuente: `toolbox/domp/selectDOMPSupport.m`.

8. Complex GMP-DOMP

8.1. Ruta interna

Se construyen U_{tr} y U_{val} . DOMP obtiene una ruta máxima de 250 regresores complejos. Para P parámetros reales:

$$K = P/2, \quad \mathcal{S}_P = \{s_1, \dots, s_K\}.$$

8.2. Normalización y lambda

Sea:

$$D = \text{diag}(\|u_1\|_2, \dots, \|u_K\|_2), \quad \tilde{U} = U D^{-1}.$$

Para $\lambda = 0$:

$$\tilde{h}_0 = \tilde{U}^\dagger y.$$

Para $\lambda > 0$:

$$\tilde{h}_\lambda = (\tilde{U}^H \tilde{U} + \lambda I)^{-1} \tilde{U}^H y.$$

Los coeficientes en la matriz física son:

$$h_\lambda = D^{-1} \tilde{h}_\lambda.$$

La lambda se elige por mínimo NMSE complejo en validation.

8.3. Refit final

La ruta se vuelve a seleccionar desde cero sobre toda identificación. Se mantiene la lambda elegida. Se ajustan todos los prefijos y se evalúan en identificación y señal completa.

8.4. Parámetros

$$P_{\text{GMP}} = 2K.$$

Fuente: toolbox/sweep/fit_complex_gmp_domp.m.

9. Modelo PN-IQ-GMP propuesto

9.1. Normalización de fase

$$r[n] = \begin{cases} \frac{x^*[n]}{|x[n]|}, & |x[n]| \neq 0, \\ 1, & |x[n]| = 0. \end{cases}$$

El objetivo y cada regresor se expresan en el marco de fase de la entrada:

$$z[n] = r[n]y[n], \quad \tilde{u}_j[n] = r[n]u_j[n].$$

9.2. Diccionario I/Q

$$f_{j,I}[n] = \Re\{\tilde{u}_j[n]\}, \quad f_{j,Q}[n] = \Im\{\tilde{u}_j[n]\}.$$

Para términos canónicos con portador $x[n]$, $f_{j,Q} = 0$ y la columna se elimina. Los auxiliares se rotan directamente. El resultado es una matriz real F .

9.3. Selección

DOMP se aplica a $F_{\text{tr}} \in \mathbb{R}^{N_{\text{tr}} \times J}$ y al objetivo complejo $z_{\text{tr}} \in \mathbb{C}^{N_{\text{tr}}}$. Para un presupuesto P :

$$M = P/2.$$

El soporte contiene M características reales, no M regresores complejos.

9.4. Ajuste independiente

Sobre el mismo soporte:

$$\tilde{c}_I = \arg \min_c \|\Re\{z\} - \tilde{F}_S c\|_2^2 + \lambda \|c\|_2^2,$$

$$\tilde{c}_Q = \arg \min_c \|\Im\{z\} - \tilde{F}_S c\|_2^2 + \lambda \|c\|_2^2.$$

La predicción rotada y la restauración son:

$$\hat{z} = F_S c_I + j F_S c_Q, \quad \hat{y}[n] = r^*[n] \hat{z}[n].$$

La lambda es común a los dos ajustes y se selecciona minimizando el NMSE complejo tras restaurar la fase.

9.5. Libertad adicional

Para una columna compleja:

$$\tilde{u} = a + jb.$$

Un coeficiente complejo convencional impone:

$$h\tilde{u} = h a + (jh) b.$$

Es decir, si se interpreta mediante dos características reales, sus coeficientes complejos están ligados:

$$g_b = jg_a.$$

PN-IQ permite:

$$\hat{z} = g_a a + g_b b, \quad g_a, g_b \in \mathbb{C},$$

sin esa restricción, y puede seleccionar a y b por separado.

9.6. Contabilidad

Cada característica seleccionada tiene un coeficiente para I y otro para Q:

$$P_{\text{PN-IQ}} = 2M.$$

El nombre recomendado es **PN-IQ-GMP**. DOMP es el método de selección, no una variante “PN-DOMP”.

Fuente: `toolbox/sweep/fit_independent_pniq_domp.m` y `factorizeGMPRegressor.m`.

10. Fixed Ridge

Las variantes fijas conservan las rutas DOMP principales y repiten el ajuste con:

$$\lambda \in \{10^{-3}, 10^{-4}, 10^{-5}\}.$$

No vuelven a seleccionar soporte. Por contrato, parámetros y FLOPs son los mismos que en la fila principal correspondiente. Solo cambian coeficientes, NMSE y rango numérico.

Fuente: `toolbox/sweep/run_fixed_ridge_sweep.m`.

11. Dataset PNNN

11.1. Características

Con $M = 13$, se toman:

$$x_n = [x[n], x[n-1], \dots, x[n-13]]$$

con extensión periódica. El vector full es:

$$\phi[n] = \begin{bmatrix} \Re\{r[n]x_n\} \\ \Im\{r[n]x_n\} \\ |x_n|^1 \\ |x_n|^3 \\ |x_n|^5 \\ |x_n|^7 \end{bmatrix} \in \mathbb{R}^{84}.$$

El objetivo es:

$$t[n] = \begin{bmatrix} \Re\{r[n]y[n]\} \\ \Im\{r[n]y[n]\} \end{bmatrix}.$$

11.2. Redundancias explícitas

$$\Im\{r[n]x[n]\} = 0, \quad \Re\{r[n]x[n]\} = |x[n]|.$$

Por ello, el modo full contiene una entrada estructuralmente cero y una duplicación con el término de envolvente de orden uno del tap actual.

Fuentes: `toolbox/pnnn/buildPhaseNormInput.m` y `buildPhaseNormDataset.m`.

12. Arquitectura y entrenamiento PNNN

12.1. Normalización

$$\bar{\phi}_d = \frac{\phi_d - \mu_{X,d}}{\sigma_{X,d}}, \quad \bar{t}_q = \frac{t_q - \mu_{Y,q}}{\sigma_{Y,q}}.$$

Los $\sigma = 0$ se sustituyen por uno.

12.2. Red

$$h = \sigma(W_1 \bar{\phi} + b_1), \quad \tilde{t} = W_2 h + b_2,$$

con $D = 84$, $H = 12$ y salida 2. La activación oculta es sigmoide y la salida es lineal.

$$P_{\text{dense}} = DH + H + 2H + 2 = H(D + 3) + 2 = 1046.$$

12.3. Selección de épocas

La red densa de selección se entrena con train interno y validation. Se conserva la red de menor validation loss y se convierte la iteración óptima en épocas.

El número máximo de épocas, el periodo de caída y la paciencia se escalan para conservar aproximadamente el número histórico de actualizaciones definido por 70 % de la señal y 150 épocas.

12.4. Refit

Tras seleccionar la época, se reinicia la red con la misma semilla y se entrena desde cero sobre toda identificación. Las estadísticas z-score se recalculan en identificación.

Fuentes: `fitFairPNNNDenseValidation.m`, `refitFairPNNNDense.m`, `scalePNNNTrainingBudget.m` y `buildFairPNNNLayer`

13. Pruning PNNN

13.1. Máscara

Se ordenan globalmente por magnitud todos los pesos de W_1 y W_2 . Los sesgos quedan siempre activos. Si el objetivo es P :

$$P_{\text{bias}} = 12 + 2 = 14, \quad P_{\text{weights}} = P - 14.$$

13.2. Selección de fine-tuning

La duración de fine-tuning se selecciona una sola vez podando la red interna al presupuesto 200. Esa duración se transfiere a todos los puntos finales.

13.3. Refit sparse

Cada presupuesto:

1. parte de la misma red densa final inmutable;
2. construye su máscara por magnitud;
3. aplica máscara a parámetros;
4. aplica máscara a gradientes;
5. actualiza con Adam;
6. reaplica la máscara tras cada actualización;
7. verifica que los pesos podados siguen en cero;
8. fine-tunea durante la duración común sobre toda identificación.

Las máscaras, antes de fine-tuning, son prefijos por magnitud de una misma fuente; las redes finales se optimizan de forma independiente.

Fuentes: `createMagnitudePruningMasks.m`, `fineTunePrunedNetwork.m`, `refitFairPNNNSparse.m` y `fit_sparse_pnnn_t`

14. Predicción PNNN

La salida normalizada se desnormaliza:

$$\hat{t} = \hat{\bar{t}} \odot \sigma_Y + \mu_Y.$$

Se reconstruye:

$$\hat{z} = \hat{t}_I + j\hat{t}_Q, \quad \hat{y}[n] = r^*[n]\hat{z}[n].$$

Fuente: `toolbox/pnnn/predictPhaseNorm.m`.

15. Métrica NMSE

Todos los modelos usan:

$$\text{NMSE}_{\text{dB}} = 10 \log_{10} \left(\frac{\sum_n |y[n] - \hat{y}[n]|^2}{\sum_n |y[n]|^2} \right).$$

Fuente: `toolbox/metrics/nmseComplexDb.m`.

16. Complejidad

16.1. Convención

Operación	FLOPs
Suma real	1
Multiplicación real	1
MAC real	2
Suma compleja	2
Multiplicación compleja	6
MAC complejo	8
Suma de bias real	1

Raíces, divisiones, valores absolutos y activaciones se reportan como operaciones especiales sin peso FLOP.

16.2. Lineales

`countModelOperations` separa generación de características, multiplicaciones por coeficientes, acumulación, normalización y restauración de fase. PN-IQ usa un `schedule structure-aware` que reutiliza magnitudes y portadores rotados.

16.3. PNNN

El coste denso incluye construcción de 84 características, dos capas, biases, 12 sigmoides y restauración. El coste sparse sustituye el número de pesos densos por pesos activos, pero mantiene todo el coste de generación de características.

El valor principal sparse presupone que una implementación omite exactamente los pesos cero. El `predict` MATLAB actual no constituye esa implementación sparse.

Fuentes: `countModelOperations.m`, `countModelFLOPs.m`, `getFLOPConvention.m`, `countPNNNFLOPs.m` y `countSparsePNNN`

17. Rango de coeficientes

17.1. Construcción lineal equivalente

En identificación se conceptualiza:

$$x_u = \frac{x}{\max_{n \in \mathcal{I}} |x[n]|}, \quad y_u = \frac{y}{\max_{n \in \mathcal{I}} |y[n]|}.$$

Cada columna se normaliza:

$$\bar{u}_k = \frac{u_k(x_u)}{\|u_k(x_u)\|_2}.$$

Se ajustan los coeficientes en esa base. Para GMP:

$$C_{\text{máx}}^{\text{GMP}} = \max_k (|\Re\{\bar{h}_k\}|, |\Im\{\bar{h}_k\}|).$$

Para PN-IQ:

$$C_{\text{máx}}^{\text{PN-IQ}} = \max_k (|\bar{c}_{I,k}|, |\bar{c}_{Q,k}|).$$

La normalización de entrada es implícita en el código principal, porque el factor global de una columna homogénea cancela al dividir por su norma. La prueba lineal reconstruye la versión explícita y verifica igualdad.

17.2. PNNN

La PNNN reporta:

$$C_{\text{máx}}^{\text{PNNN}} = \max_{\theta_i \text{ activo}} |\theta_i|$$

en la parametrización z-score, incluyendo biases. No es la misma parametrización que la de los modelos lineales.

18. Selección del punto operativo

Para cada presupuesto P y familia m :

$$G_m(P) = \text{NMSE}_m(P) - \min_{P \leq q \leq P+100} \text{NMSE}_m(q).$$

Se selecciona el menor P con ventana completa para el que:

$$G_m(P) \leq 0.20 \text{ dB} \quad \forall m.$$

El resultado es $P = 340$.

Fuente: `toolbox/sweep/selectOperatingPoint.m`.

19. Espectros y figuras temporales

19.1. Welch

$$e_m[n] = y[n] - \hat{y}_m[n].$$

Todas las señales y errores se procesan conjuntamente con:

- Hann periódica, 2048 muestras;
- 75 % de solapamiento;
- $N_{\text{FFT}} = 16384$;
- espectro bilateral centrado;
- referencia: máximo de PSD de la salida medida;
- suelo numérico: -150 dB .

19.2. Tiempo

Se seleccionan las 1000 muestras centrales. Se exportan dos figuras:

1. magnitud + parte real;
2. magnitud + parte imaginaria.

La superposición visual significa que los residuos son pequeños frente a la señal, no que los NMSE sean iguales.

Fuentes: `computeSelectedPointSpectra.m` y `run_selected_comparison.m`.

20. Widely-linear GMP auxiliar

El probe construye:

$$U_{\text{WL}} = [U, U^*]$$

y selecciona 170 átomos con DOMP para conservar 340 parámetros reales. No forma parte del sweep canónico y fija actualmente el directorio de resultados.

Modelo	NMSE full-signal	Mejora vs. GMP
Complex GMP	-38.85998	0
WL-GMP	-38.86672	0.00674
PN-IQ	-42.74017	3.88019

El resultado muestra que concatenar U^* no reproduce la ganancia de PN-IQ.

21. Resultados auditados en 340 parámetros

Familia	NMSE full-signal	FLOPs/muestra	Máx. escalar
Complex GMP-DOMP	-38.85998	1807	6.34896×10^6
PN-IQ-GMP + DOMP	-42.74017	1095	4.59256×10^6
Sparse PNNN N12	-39.24296	840	2.17243

PN-IQ mejora 3.88019 dB respecto a GMP. Las referencias Ridge reducen el rango numérico lineal a aproximadamente 86–132, con pérdida de NMSE.

22. Checkpoints y reproducibilidad

La identidad SHA-256 del sweep incorpora:

- firma de experimento;
- rejillas de parámetros y lambdas;
- especificación de población GMP;
- tolerancia DOMP;
- configuración PNNN;
- entrenamiento y pruning.

Los checkpoints lineal, Ridge, denso y sparse se rechazan si la identidad no coincide. La red densa se firma además con sus learnables y estadísticas de normalización.

23. Hallazgos y acciones

23.1. Crítico: clear dentro del main

El main actual comienza con:

```
clear; clc; close all force;
```

`clear` elimina las variables del workspace de la función y puede borrar el argumento `selectedParameters`. Debe quedar, como máximo:

```
clc;  
close all force;
```

o no ejecutar ninguna limpieza dentro de la función.

23.2. Nombre del método

Sustituir:

- “PN-DOMP”;
- “PN-IQ PN-DOMP”.

por:

- modelo: **PN-IQ-GMP**;
- identificación: **DOMP-based sparse support selection**;
- leyenda compacta: **PN-IQ-GMP**.

23.3. Limitaciones que deben declararse

1. full-signal incluye identificación;
2. PNNN y lineales no comparten parametrización para $C_{\text{máx}}$;
3. PNNN sparse FLOPs presupone kernel sparse;
4. los espacios candidatos difieren;
5. la PNNN full contiene una entrada cero y una duplicada;
6. WL probe tiene path de resultados hardcoded.

24. Preguntas de defensa y respuestas

¿Sobre qué se aplica DOMP?

Sobre columnas candidatas. En GMP, columnas complejas. En PN-IQ, columnas reales I/Q. Nunca se aplica sobre los coeficientes ya ajustados.

¿Cuándo se ejecuta DOMP?

Una vez en train interno para la ruta usada al seleccionar lambda y otra vez en toda identificación para el soporte final.

¿Comparten soporte I y Q?

Sí. Las dos salidas usan el mismo conjunto de características reales; sus coeficientes se estiman por separado.

¿La PNNN usa DOMP?

No. Se entrena densa y se poda globalmente por magnitud.

¿Los modelos sparse PNNN forman una trayectoria iterativa?

No. Todos parten de una misma fuente densa final y se fine-tunean independientemente.

¿Por qué PN-IQ es más flexible?

Porque elimina la restricción $g_b = jg_a$ entre los pesos de las componentes real e imaginaria de un regressor rotado y permite seleccionarlas por separado.

¿Es independiente el NMSE full-signal?

No. Incluye identificación.

¿Los FLOPs son tiempo de ejecución?

No. Son cuentas analíticas de sumas y multiplicaciones bajo una convención fija; las operaciones especiales quedan separadas.

A. Mapa código–concepto

Concepto	Implementación
Configuración	config/getFairDOMPComparisonConfig.m
Entrada canónica	main_sweep_and_comparison.m
Pipeline	run_parameter_sweep.m
Split	toolbox/splits/buildCommonComparisonSplit.m
Selector 10 %	toolbox/pn_gmp_comparison/sel_indices.m
Población GMP	GMP_createRegressorManager.m, regressorManager.m
Evaluación GMP	buildGMPRegressorRows.m
DOMP	toolbox/domp/selectDOMPSupport.m
Complex GMP	toolbox/sweep/fit_complex_gmp_domp.m
PN-IQ	toolbox/sweep/fit_independent_pniq_domp.m
Ridge	toolbox/sweep/run_fixed_ridge_sweep.m
Features PNNN	buildPhaseNormInput.m, buildPhaseNormDataset.m
Arquitectura	buildFairPNNNLayers.m
Normalización	computePNNNNormalization.m
Dense validation	fitFairPNNNDenseValidation.m
Dense refit	refitFairPNNNDense.m
Máscaras	createMagnitudePruningMasks.m
Fine-tuning	fineTunePrunedNetwork.m
Sparse refit	refitFairPNNNSparse.m
Predicción	predictPhaseNorm.m
NMSE	nmseComplexDb.m
Complejidad	countModelOperations.m, countModelFLOPs.m
Selección 340	selectOperatingPoint.m
Espectro	computeSelectedPointSpectra.m
Exportación	exportPaperFigure.m
Probe WL	run_widely_linear_gmp_probe.m

B. Glosario de nombres recomendado

Complex GMP-DOMP

Baseline complejo con soporte seleccionado mediante DOMP.

PN-IQ-GMP

Modelo propuesto.

DOMP-selected PN-IQ-GMP

Forma descriptiva completa.

Sparse PNNN N12

Benchmark neural de 12 neuronas ocultas.

Full-signal NMSE

NMSE sobre todo el registro, incluyendo identificación.

Identification NMSE

NMSE sobre el bloque del 10 %.

Internal validation

Subconjunto de identificación usado solo para selección.