

PN-GMP, DOMP y comparación justa con PNNN

Manual técnico y guía para la defensa oral

Proyecto PNNN

Ejecución validada: 20260714_102201
14 de julio de 2026

Este documento explica el estudio final sin regenerar resultados. Las cifras se leen directamente de los CSV congelados de la ejecución indicada. La convención local se conserva: X es la entrada y Y la salida del bloque modelado; `xy_forward` no se interpreta por sí solo como PA-forward.

Mensaje central. La formulación PN-IQ acoplada es una representación real exactamente equivalente al GMP complejo. La mejora de NMSE aparece al relajar el acoplamiento I/Q en coordenadas normalizadas en fase. En esta captura, Independent PN-IQ alcanza el menor NMSE sobre la señal completa; una PNNN N12 podada iguala exactamente sus 358 parámetros activos y necesita menos FLOPs si la implementación omite los pesos nulos. No existe un ganador universal sin fijar plataforma y criterio.

1. Resumen ejecutivo

El objetivo experimental es comparar modelos de señal compleja con memoria en un protocolo común y con presupuestos de parámetros explícitos. El punto de partida es un Generalized Memory Polynomial (GMP): una población de regresores complejos combina muestras actuales y retardadas con términos de envolvente. DOMP selecciona un soporte disperso durante la identificación. Después, el modelo inferido solo evalúa las columnas seleccionadas y sus coeficientes; DOMP no forma parte de la inferencia.

La normalización de fase usa

$$r(n) = \frac{x^*(n)}{|x(n)|}, \quad r(n) = 1 \text{ si } x(n) = 0, \quad (1)$$

y rota con el mismo $r(n)$ toda la fila del GMP y el objetivo. La formulación *coupled PN-IQ* transforma el sistema complejo en una matriz real por bloques, conservando exactamente dos parámetros reales por coeficiente complejo. El error relativo de predicción frente al GMP es 0,000000000013: equivalencia numérica.

La variante *independent PN-IQ* conserva las features reales normalizadas, pero ajusta I y Q con coeficientes independientes. Ya no impone la estructura de una multiplicación compleja y, por tanto, es una clase más general. Los controles sin PN, con GMP parameter-matched y con PN-IQ reducido separan el efecto de las coordenadas, el acoplamiento y el número de parámetros.

La captura tiene 491,520 muestras. La identificación contiene 19,661 (aproximadamente 4%) y está incluida en la evaluación sobre la señal completa. Dentro de identificación, 16,711 muestras de entrenamiento interno y 2,950 de validación interna sirven exclusivamente para seleccionar λ , épocas y duración del fine-tuning. Después, todos los soportes, coeficientes y redes finales se reajustan desde cero usando las 19,661 muestras. La señal completa no interviene en selección.

Independent PN-IQ obtiene $-38,534$ dB con 358 parámetros; el GMP parameter-matched, $-38,17$ dB con 358; y PNNN N12 sparse, $-35,9$ dB con 358. La primera mejora al GMP matched en 0.363 dB y a la PNNN sparse en 2.634 dB. La red sparse, a su vez, mejora 2.267 dB a H4 dense, pero empeora 0.731 dB respecto a N12 dense. PN-IQ usa 1,062 FLOPs/muestra; N12 sparse usa 876 cuando se omiten pesos cero, o 2,252 si se ejecutan las matrices completas, además de 12 ELU y otras operaciones adicionales. La evaluación completa incluye las muestras de identificación y no es un test independiente de generalización.




Figura 1: Flujo validado. La señal completa contiene la identificación y no selecciona hiperparámetros.

2. Contexto de DPD y GMP

La predistorsión digital busca compensar no linealidad y memoria antes de la cadena física, pero este repositorio formula cada identificación con la convención local entrada X /salida Y del bloque concreto. Un PA con memoria no depende solo de $x(n)$: depende también de retardos y envolventes recientes. Un GMP representa esa dependencia mediante ramas alineadas y cruzadas. En forma matricial,

$$\mathbf{y} = \mathbf{U}\mathbf{h} + \mathbf{e}, \quad (2)$$

donde cada columna de $\mathbf{U}$ es un regresor complejo y cada elemento de $\mathbf{h}$ es su coeficiente complejo. Las ramas A/B/C combinan un carrier retardado con una potencia de envolvente actual, adelantada o retardada; los builders del proyecto conservan además los auxiliares definidos por la población.

Seleccionar 100 regresores complejos significa mantener 100 columnas complejas, no 100 escalares reales. Si $h_j = \alpha_j + j\beta_j$, cada coeficiente aporta dos componentes reales. Por ello,

$$100 \text{ coeficientes complejos} = 200 \text{ parámetros reales}. \quad (3)$$

Esta contabilidad es la que hace posible una comparación parameter-matched con modelos reales y redes.

3. Phase normalization

Para cada fila evaluada se calcula (1) y se aplica

$$\mathbf{U}_{\text{PN}}(n, :) = r(n)\mathbf{U}(n, :), \quad y_{\text{PN}}(n) = r(n)y(n). \quad (4)$$

El caso $x(n) = 0$ usa $r(n) = 1$ y evita división por cero. La implementación valida índices y finitud y devuelve una rotación columna.

La misma rotación debe multiplicar *toda la fila*. No se construye primero $z(k) = r(k)x(k)$ para introducirlo en un GMP convencional: un tap $x(n-m)$ quedaría rotado con $r(n-m)$, cuando el marco deseado es el de la muestra actual $r(n)$. Para un regresor

$$u(n) = x(n-m)E(n), \quad x(k) = |x(k)|e^{j\phi(k)}, \quad (5)$$

con $E(n)$ real, se obtiene

$$r(n)u(n) = |x(n-m)|E(n)e^{j[\phi(n-m)-\phi(n)]}. \quad (6)$$

Se elimina la fase absoluta del carrier de referencia, pero se conserva amplitud, memoria y fase relativa. Si $m = 0$, la diferencia de fase es cero y la componente Q de esa feature es exactamente nula. Solo esas columnas Q estructuralmente nulas se eliminan en las variantes independientes; ello no convierte el coeficiente del GMP acoplado en real.

La extensión temporal del constructor compartido usa índices periódicos para que todas las variantes observen el mismo dominio. Tras predecir en el marco PN, la salida principal se restaura como

$$\hat{y}(n) = r^*(n)\hat{y}_{\text{PN}}(n). \quad (7)$$

PN no es necesario para escribir una matriz compleja en forma real. Su papel es elegir coordenadas relativas a la fase actual antes de relajar el modelo I/Q.

4. Formulación PN-IQ acoplada

Sea $u = u_I + ju_Q$ y $h = \alpha + j\beta$. Entonces

$$uh = (u_I\alpha - u_Q\beta) + j(u_I\beta + u_Q\alpha). \quad (8)$$

Las dos vistas equivalentes son

$$\begin{bmatrix} y_I \\ y_Q \end{bmatrix} = \begin{bmatrix} u_I & -u_Q \\ u_Q & u_I \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \end{bmatrix}, \quad \begin{bmatrix} y_I \\ y_Q \end{bmatrix} = \begin{bmatrix} \alpha & -\beta \\ \beta & \alpha \end{bmatrix} \begin{bmatrix} u_I \\ u_Q \end{bmatrix}. \quad (9)$$

Para múltiples regresores, con $\mathbf{U}_{\text{PN}} = \mathbf{U}_I + j\mathbf{U}_Q$,

$$\begin{bmatrix} \mathbf{y}_I \\ \mathbf{y}_Q \end{bmatrix} = \underbrace{\begin{bmatrix} \mathbf{U}_I & -\mathbf{U}_Q \\ \mathbf{U}_Q & \mathbf{U}_I \end{bmatrix}}_{\mathbf{U}_R} \begin{bmatrix} \boldsymbol{\alpha} \\ \boldsymbol{\beta} \end{bmatrix}. \quad (10)$$

Se llama *acoplada* porque los cuatro bloques no son independientes: la misma α_j y β_j gobiernan simultáneamente ambas salidas y aparecen con signos fijados. Hay dos grados de libertad por regresor, exactamente los de h_j . La rotación de fila es unitaria, de modo que el ajuste y la restauración producen el mismo GMP salvo redondeo. El resultado validado es 0,000000000013 de error relativo sobre la señal completa y el NMSE coincide a la precisión mostrada.

Una implementación *structure-aware* puede evitar operar con las Q exactamente nulas y compartir envolventes y potencias. Es un ahorro de operaciones, no una licencia para eliminar β_j : una feature real aún admite coeficiente complejo y conserva dos parámetros. El valor de la formulación acoplada es servir como puente algebraico, prueba de equivalencia y base común para estudiar restricciones más flexibles.

5. Formulación PN-IQ independiente

Una transformación real general de una feature I/Q es

$$\begin{bmatrix} y_I \\ y_Q \end{bmatrix} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} u_I \\ u_Q \end{bmatrix}. \quad (11)$$




Figura 2: La diferencia esencial no es “complejo frente a real”, sino la estructura impuesta entre I y Q.

Ya no se exige $d = a$ ni $c = -b$ (según convención de signos). En el caso multifeature se forma una matriz real $\mathbf{F}$ con las componentes I/Q retenidas y se ajustan dos salidas:

$$\mathbf{y}_I = \mathbf{F}\mathbf{a}, \quad \mathbf{y}_Q = \mathbf{F}\mathbf{b}. \quad (12)$$

Una feature genérica puede contribuir con cuatro grados de libertad a la pareja de salidas, frente a dos en una multiplicación compleja. Por eso el modelo puede reducir NMSE, pero también sobreparametrizar y dejar de ser un GMP equivalente.

Cuadro 1: Controles que separan coordenadas, acoplamiento y presupuesto.

Modelo	Entrada y salida	PN	Acoplamiento	Parámetros	Interpretación
Coupled PN-IQ	$U_{\text{PN}} \rightarrow (y_I, y_Q)$	sí	complejo	200	GMP exacto
Independent PN-IQ full	$F_{\text{PN}} \rightarrow y_I, y_Q$	sí	libre	358	extensión principal
Independent I/Q no PN	$[\Re U, \Im U] \rightarrow y_I, y_Q$	no	libre	394	control de coordenadas
Reduced independent PN-IQ	100 features compartidas	sí	libre	200	control de presupuesto
Complex GMP matched	columnas GMP complejas	no	complejo	358	control parameter-matched

En el soporte DOMP-100, las 200 columnas I/Q brutas pierden 21 columnas Q exactamente nulas; quedan 179 features y dos coeficientes de salida por feature: 358 parámetros. El control sin PN conserva 197 features, es decir, 394 parámetros. La versión reducida selecciona con DOMP 100 features reales compartidas y les asigna dos salidas: 200 parámetros. El GMP matched usa 179 regresores complejos, 358 parámetros: coincide exactamente con el objetivo congelado del proceso de selección.

6. Por qué PN importa en el modelo independiente

Una multiplicación compleja es equivariante a rotaciones. En el acoplado,

$$\text{rotación} \rightarrow \text{multiplicación compleja} \rightarrow \text{rotación inversa} = \text{mismo GMP}.$$

Por eso PN no cambia su clase ni su NMSE. Una matriz real general como (11) no conmuta necesariamente con todas las rotaciones. Al romper el acoplamiento,

$$\text{rotación} \rightarrow \text{transformación I/Q general} \rightarrow \text{rotación inversa} = \text{modelo dependiente del marco PN}.$$

El control Independent I/Q without PN tiene la misma libertad conceptual sin elegir ese marco. Su full-signal NMSE es $-37,81$ dB, frente a $-38,534$ dB con PN: en esta captura, PN aporta 0.723 dB dentro de la familia independiente. Esto aísla un efecto de coordenadas, no prueba una ventaja universal.

7. DOMP

La población GMP es mayor que el soporte inferido. La selección dispersa busca columnas informativas sin evaluar todas en el modelo final. OMP selecciona por correlación y actualiza el residuo; DOMP añade una ortogonalización explícita de los candidatos respecto al subespacio ya elegido, reduciendo selecciones redundantes en diccionarios correlacionados. La versión final usa solo DOMP; OMP se excluyó para mantener una única regla validada y comparable.

Listing 1: Pseudocódigo resumido de DOMP.

```

Z <- normalize_columns(X); residual <- y; support <- []
repeat until maxSupport or stopping criterion:
    score <- FrobeniusNorm(Z' * residual, over outputs)
    j <- largest eligible score
    support <- support union {j}
    q <- normalized orthogonal candidate Z(:,j)
    Z <- Z - q * (q' * Z) % candidate re-orthogonalization
    coefficients <- min_norm_LS(X(:,support), y)
    residual <- y - X(:,support) * coefficients
end

```

`selectDOMPSupport.m` normaliza columnas, excluye normas por debajo de tolerancia, impide índices repetidos, acepta matrices y targets complejos o multisalida, puntúa con norma de Frobenius, y ajusta sobre las columnas *originales*. Usa QR si hay rango completo y `lsqminnorm` en caso contrario. Guarda en `history` índice, correlación, norma del residuo, condición, tiempo y ortogonalidad. Las tolerancias de columna, correlación y residuo, junto con el máximo de soporte, definen la parada. Dada la misma matriz, target y configuración, el proceso es determinista.

DOMP actúa solo dentro de identificación para elegir soporte (y en el flujo `parameter-matched` o reducido correspondiente). Tras la selección interna, el soporte final se regenera con las 19,661 muestras de identificación. El soporte DOMP-100 congelado se reutiliza en el `coupled`. No se suma su coste a FLOPs/muestra de inferencia. El algoritmo no se presenta como aportación propia; la referencia de proyecto es Becerra et al., “A Doubly Orthogonal Matching Pursuit Algorithm for Sparse Predistortion of Power Amplifiers” [1]. Los artefactos disponibles no fijan más datos bibliográficos, por lo que no se inventan año ni revista.

8. Diseño de la comparación justa

La medida configurada es `experiment20260429T134032_xy`, con 491,520 muestras y eliminación de DC. El mapping guardado es `xy_forward`, que solo identifica la convención local X/Y . El constructor aplica la misma extensión temporal periódica a los modelos con memoria.

Con semilla 1004, el selector original elige aproximadamente el 4 % para identificación. Con semilla 42, un split estratificado por amplitud de $|Y|$ (10 bins) divide ese dominio en entrenamiento y validación internos:

$$|\mathcal{I}_{\text{train}}| = 16,711, \quad |\mathcal{I}_{\text{val}}| = 2,950, \quad |\mathcal{I}| = 19,661, \quad |\mathcal{F}| = 491,520.$$

Los dos subconjuntos internos no se intersectan y su unión es identificación. El dominio completo $\mathcal{F}$ contiene todos los índices de identificación. Por tanto, la evaluación sobre la señal completa no es un hold-out disjunto.




Figura 3: Identificación incluida en la señal completa. La barra inferior amplía su división interna de selección.

Para modelos lineales, el subconjunto interno de entrenamiento selecciona soporte y se compara en validación interna la rejilla

$$\lambda \in \{0, 10^{-6}, 10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}\}.$$

La ejecución validada elige $\lambda = 0$ en todas las variantes. Congeladas las decisiones, DOMP vuelve a generar cada soporte final y los coeficientes se ajustan con identificación completa.

Para PNNN, el split interno selecciona 3,083 épocas para H4, 3,150 para N12 y 392 épocas de fine-tuning. Cada red final se reinicia con la misma semilla, calcula su normalización sobre identificación completa y ejecuta exactamente el número de épocas seleccionado sin early stopping. N12 sparse se poda y se afina también sobre identificación completa. La señal completa solo se predice cuando los modelos están congelados.

La comparación anterior no era justa si mezclaba identificación al 4 %, split histórico 70/15/15, una red de unos 1200 parámetros y conjuntos de evaluación distintos. El protocolo actual comparte identificación, evaluación completa, función NMSE y cuenta parámetros reales activos. El objetivo sparse se calcula dinámicamente para igualar los 358 parámetros de Independent PN-IQ. Aun así, persisten diferencias de optimización: los modelos lineales resuelven ajustes convexos y la red sparse parte de una arquitectura densa sobredimensionada.

El experimento disjunto anterior se conserva en `results/fair_domp_comparison/20260714_013938` como control exploratorio histórico, pero no es el resultado principal.

9. PNNN dense y sparse

La PNNN recibe $D = 84$ features phase-normalized y produce dos salidas reales que se recombinan y se restauran a la fase original. Tiene una capa oculta ELU y una salida lineal de dos componentes. Para H neuronas,

$$P(H) = DH + H + 2H + 2 = H(D + 3) + 2. \quad (13)$$

Así, H4 contiene 350 parámetros y H12, 1046. Ambas usan seed 42. H4 dense sirve como control denso cercano a 358 parámetros; N12 dense mide la capacidad de la arquitectura ancha; N12 sparse empieza con esa capacidad y se poda hasta 358 parámetros activos.

La selección interna fija 3,083 épocas para H4 y 3,150 para N12. El ajuste final parte de cero y usa las 19,661 muestras en cada una de esas épocas. En N12 sparse, el pruning global por magnitud elimina 688 de 1032 pesos (66.667%), protege los 14 biases, conserva 344 pesos y totaliza 358 parámetros. Los pesos podados quedan congelados y el modelo se afina durante 392 épocas fijas usando identificación completa. Proteger biases evita que el presupuesto desactive offsets accidentalmente; podarlos tendría otra semántica y contabilidad.

Una red ancha sparse puede conservar rutas útiles distribuidas que una red H4 no puede representar, aunque no hay garantía: depende de inicialización, optimización y patrón. N12 sparse logra $-35,9$ dB, mejora H4 en 2.267 dB, pero N12 dense alcanza $-36,631$ dB y es 0.731 dB mejor que la podada.




Figura 4: La red sparse conserva la arquitectura H12, no se sustituye por una red estrecha.

10. Métrica NMSE

Todos los modelos usan la misma definición temporal compleja:

$$\text{NMSE}_{\text{dB}} = 10 \log_{10} \frac{\sum_n |y(n) - \hat{y}(n)|^2}{\sum_n |y(n)|^2}. \quad (14)$$

Más negativo significa menor energía de error relativa. Una ventaja de 0.3 dB es pequeña pero medible sobre el mismo dominio; 1 dB es más clara; 3 dB equivale a aproximadamente dividir por dos la potencia de error. Estas interpretaciones no sustituyen repetición estadística. No se mezclan NMSE temporal y frecuencial ni dominios distintos. Full-signal NMSE incluye identificación y no cuantifica por sí solo generalización independiente.

11. Parámetros y comparación parameter-matched

Cuadro 2: Presupuesto real y soporte de la ejecución validada.

Modelo	Coef. complejos	Features efectivas	Parámetros reales	Dif. objetivo
Complex GMP DOMP-100	100	100	200	–
Coupled PN-IQ	100	200 bloques I/Q	200	–
Independent PN-IQ full	–	179	358	0
Complex GMP matched	179	179	358	0
Independent I/Q no PN	–	197	394	+36
Reduced independent PN-IQ	–	100	200	–158
PNNN H4 dense	–	–	350	–8
PNNN N12 dense	–	–	1,046	+688
PNNN N12 sparse	–	–	358	0

El objetivo de 358 proviene de las 179 features PN efectivas por dos salidas. El GMP parameter-matched selecciona exactamente 179 coeficientes complejos, es decir, 358 parámetros reales. En redes se cuentan pesos y biases activos; N12 sparse tiene $344+14=358$. Los tres modelos principales quedan, por tanto, exactamente igualados en este presupuesto.

12. FLOPs y complejidad

Se usa una única cifra principal: **FLOPs/muestra**, definida como el número de sumas y multiplicaciones requerido para producir una muestra compleja de salida a partir de sus muestras de entrada. El alcance es el mismo para todos los modelos: generación de las features utilizadas, productos por coeficientes o pesos, acumulaciones, biases, normalización de fase y restauración cuando corresponden.

La convención asigna 1 FLOP a una suma/resta o multiplicación real, 2 a una suma compleja y 6 a una multiplicación compleja. Para

$$(a + jb)(c + jd) = (ac - bd) + j(ad + bc)$$

hay cuatro multiplicaciones y dos sumas reales: 6 FLOPs. Se informan por separado módulos, raíces, divisiones, ELU y exponenciales porque no se ha acordado una conversión homogénea a FLOPs.

Cuadro 3: Comparación principal: mismo presupuesto de 358 parámetros reales.

Modelo	Parámetros	Full-signal NMSE	FLOPs/muestra	Operaciones adicionales/muestra
Independent PN-IQ	358	−38,534 dB	1,062	12 módulos/raíces, 2 divisiones
Complex GMP matched	358	−38,17 dB	1,899	14 módulos/raíces
PNNN N12 sparse	358	−35,9 dB	876	14 módulos/raíces, 2 divisiones, 12 ELU (hasta 12 exp)

El GMP usa operaciones complejas y envolventes compartibles. PN-IQ cuenta la generación de features, productos por coeficiente, acumulaciones, normalización y restauración. Coupled e independent full coinciden en 1062 FLOPs aunque tengan 200 y 358 parámetros: el acoplado necesita la aritmética cruzada equivalente a productos complejos, mientras el independiente explota componentes Q nulas y ajusta dos salidas. Parámetros y operaciones no son la misma magnitud.

La cifra principal de N12 sparse, 876 FLOPs/muestra, supone que la implementación omite multiplicaciones por sus pesos exactamente nulos. Ejecutar las matrices originales completas requiere 2252 FLOPs/muestra. Las redes añaden ELU: H4 tiene 4 y N12, 12 por muestra. Ninguna de estas cifras demuestra automáticamente tiempo MATLAB, coste FPGA, latencia o energía.




Figura 5: Comparación principal. El conteo sparse supone que se omiten pesos nulos; las etiquetas indican parámetros reales.



Figura 6: N12 sparse: 876 FLOPs/muestra omitiendo pesos nulos frente a 2252 si se ejecutan las matrices completas. Las operaciones adicionales se informan aparte.

Cuadro 4: Resultados numéricos de `comparison_results.csv`.

Modelo	Entr. int.	Val. int.	Identificación	Señal completa	λ	Soporte
Complex GMP DOMP-100	-39,082232	-38,390517	-39,039827	-37,977836	0	100
Coupled PN-IQ	-39,082232	-38,390517	-39,039827	-37,977836	0	100
Independent PN-IQ full	-39,733478	-38,905534	-39,723982	-38,533647	0	100
Complex GMP matched	-39,4283	-38,572774	-39,384615	-38,170265	0	179
Independent I/Q no PN	-39,362195	-38,006188	-39,258029	-37,810459	0	100
Reduced independent PN-IQ	-39,086473	-38,299528	-39,025189	-38,057859	0	100
PNNN H4 dense	-34,238205	-33,511988	-34,281119	-33,633234	-	-
PNNN N12 dense	-37,554211	-36,630285	-37,484585	-36,631023	-	-
PNNN N12 sparse	-36,281732	-35,524389	-36,574324	-35,899781	-	-

13. Resultados finales

Las diferencias sobre la señal completa, redondeadas a tres decimales, son:

- Independent PN-IQ mejora 0.363 dB al GMP parameter-matched.
- Independent PN-IQ mejora 2.634 dB a PNNN N12 sparse.
- PNNN N12 sparse mejora 2.267 dB a H4 dense.
- PNNN N12 dense mejora 0.731 dB a N12 sparse.
- Reduced PN-IQ (200 parámetros) mejora 0.080 dB al GMP DOMP-100.

En coste, N12 sparse requiere 876 FLOPs/muestra si se omiten pesos nulos y 2252 si se ejecutan las matrices completas, mientras PN-IQ full usa 1062. La red sparse ahorra 186 FLOPs bajo la primera implementación, pero requiere 1190 más bajo la segunda y mantiene 12 ELU adicionales.




Figura 7: NMSE sobre la señal completa frente a parámetros activos. Los puntos proceden del CSV congelado.

14. Interpretación científica

Lo demostrado en esta ejecución

- La representación coupled PN-IQ reproduce el GMP complejo con error relativo 0,000000000013.
- Relajar el acoplamiento mejora el full-signal NMSE del coupled de $-37,978$ a $-38,534$ dB.
- Con 358 parámetros en ambos modelos, Independent PN-IQ supera 0.363 dB al GMP matched.
- El control sin PN queda 0.723 dB por detrás de Independent PN-IQ.
- N12 sparse supera a H4 dense con presupuesto parecido, y los FLOPs se han contado bajo una convención explícita.

Lo que sugieren, sin probar universalidad

Las coordenadas PN parecen útiles cuando se libera la transformación I/Q. El modelo lineal independiente puede aprovechar bien el régimen de pocos datos. La red ancha y podada puede conservar conexiones que H4 no representa. Son hipótesis consistentes con esta captura, no leyes generales.

Lo que no se ha demostrado

No se demuestra superioridad universal, hardware, consumo, latencia, novedad absoluta, ni generalización a otros PAs, señales o capturas. Tampoco se ha hecho una campaña amplia de seeds neuronales. Los FLOPs son analíticos y no equivalen a tiempo. Como la señal completa contiene identificación, tampoco constituye un test independiente

de generalización. No se presentan ACPR ni EVM demodulada porque no hay una evaluación validada dentro de este resultado.

15. Novedad y relación con trabajos previos

Phase normalization, separación I/Q, representación real de productos complejos, DOMP y redes phase-normalized no son ideas nuevas por separado. Hasta donde se ha podido comprobar, la aportación potencialmente novedosa es la combinación concreta: PN aplicado explícitamente a filas de una base GMP, derivación coupled exactamente equivalente, extensión independent, controles de coordenadas y presupuesto, comparación con una PNNN parameter-matched y análisis de FLOPs. En una publicación conviene usar “aportación potencialmente novedosa” o *to the best of our knowledge*, nunca “first ever” sin una revisión bibliográfica sistemática.

15.1. Decisiones de implementación y trazabilidad

Cuadro 5: Qué se hizo, motivo, alternativa y limitación.

Decisión	Implementación	Motivo/problema evitado	Alternativa y limitación
Rotación por fila	<code>computePhaseNorm</code> <code>GMPRotation</code>	Un marco común $\phi(n)$ para todos los taps	Rotar cada tap cambia el modelo; PN conserva dependencia del marco
$x(n) = 0$	$r = 1$	Evita división por cero	Otro valor unitario sería posible; convención fija
Extensión temporal	Índices periódicos compartidos	Igual dominio para todos	Recorte perdería bordes y cambiaría muestras
DC	Eliminación activada	Protocolo guardado común	Mantener DC sería otro experimento
Features PN	<code>buildPhaseNormalized</code> <code>IQRegressors</code>	Reutiliza población y misma rotación	Generar señal global rotada usaría fases erróneas
Q nulas	<code>removeStructurally</code> <code>ZeroQFeatures</code>	Elimina solo ceros exactos	Umbral aproximado introduciría reducción no controlada
Soporte coupled	DOMP-100 complejo compartido	Prueba equivalencia en mismo soporte	Reseleccionar podría confundir soporte y formulación
Parameter matched	DOMP complejo con 179 coeficientes	Iguala exactamente 358 parámetros reales	Igualar regresores ignoraría 2 parámetros/coeficiente
λ	Split interno, rejilla congelada	Señal completa no selecciona	CV más amplia cuesta identificación; aquí gana 0
Escalado	Normas de columnas repetidas por pareja	Ridge equivalente y condición controlada	Escalas I/Q independientes rompen equivalencia
Restauración	$\hat{y} = r * \hat{y}_{PN}$	Devuelve el marco original	Omitirla evaluaría otra señal
PN reducido	<code>selectShared</code> <code>IQFeatures</code>	100 features comunes a dos salidas	Selección separada cambia presupuesto y soporte
Refit PNNN	Reinicio y épocas fijas con identificación completa	Todos los modelos ajustan las mismas 19,661 muestras	Usar solo entrenamiento interno dejaría menos datos para la red
Objetivo PNNN	358 parámetros dinámicos	Igual a PN-IQ full	Un objetivo fijo puede quedar desaparejado
Pruning	Global, no estructurado, por magnitud	Preserva conexiones más útiles globalmente	Structured sparsity facilitaría hardware, no se ensayó
Biases	Protegidos	Mantiene offsets y cuenta 14	Podarlos cambia arquitectura efectiva
Freeze + fine-tune FLOPs	Máscara fija Una cifra común y operaciones adicionales separadas	Evita que reaparezcan pesos Mismo alcance de inferencia para todos	Regrowth sería otro algoritmo Medición temporal depende de plataforma
Predicciones	Señal completa en artefacto final	Mismo dominio para todos los modelos	Contiene identificación; no sustituye hold-out ni multi-captura

Decisión	Implementación	Motivo/problema evitado	Alternativa y limitación
Asserts/tests	Invariantes de split, soporte y dimensiones	Detecta fugas y desajustes	No reemplaza verificación experimental externa

Cuadro 6: Trazabilidad científica.

Concepto	Función/script principal	Resultado generado
Phase normalization	<code>computePhaseNormGMPRotation.m</code> , <code>buildPhaseNormalizedIQRegressors.m</code>	Regresores PN y predicción restaurada
DOMP	<code>selectDOMPSupport.m</code> , <code>runPNGMPDOMPStudy.m</code>	<code>domp_supports.mat</code> , history CSV
Coupled real	<code>complexToCoupledReal.m</code> , <code>fitPhaseNormGMPReal.m</code>	GMP/PN-IQ equivalente
Independent PN-IQ	<code>fitIndependentIQGMP.m</code> , <code>predictIndependentIQGMP.m</code>	PN-IQ full y reducido
Parameter matching	<code>runPNGMPDOMPStudy.m</code>	GMP matched congelado
Sparse PNNN	<code>refitFairPNNNDense.m</code> , <code>refitFairPNNNSparse.m</code>	modelos finales ajustados con identificación completa
NMSE	<code>nmseComplexDb.m</code>	columnas NMSE CSV
FLOPs	<code>countModelFLOPs.m</code> , <code>countPNNNFLOPs.m</code> , <code>countSparsePNNNFLOPs.m</code>	<code>complexity_flops.csv</code>
Reporte	<code>run_fair_PNNN_vs_PNGMP_DOMP.m</code>	CSV, MAT, PNG, PDF y predicciones full-signal
Tests	<code>run_domp_unit_test.m</code> , <code>run_fair_comparison_smoke_test.m</code>	asserts PASS/FAIL

16. Limitaciones y trabajo futuro

Limitaciones: una captura principal; un número limitado de seeds de PNNN; régimen fijo de identificación al 4 %; FLOPs analíticos; sin síntesis hardware ni cuantización; sin ACPR/EVM demodulada validada; coste de entrenamiento no igualado; dependencia de arquitectura, hiperparámetros y población GMP. La red sparse se entrena sobredimensionada, mientras los lineales resuelven problemas convexos; igualar parámetros activos no iguala proceso de optimización.

Trabajo futuro: varias capturas, señales y PAs; múltiples seeds; barridos de datos; punto fijo; kernels DSP/FPGA; sparsity estructurada; latencia y energía medidas; ACPR/EVM válidos; selección conjunta de soporte y acoplamiento; y estudio de generalización fuera de distribución.

17. Preguntas previsibles de los tutores

1. **¿El PN-IQ acoplado es un modelo nuevo?** No como clase funcional: es una representación real exactamente equivalente al GMP sobre el mismo soporte.
2. **¿Por qué da el mismo NMSE?** La rotación es unitaria, la matriz por bloques representa el mismo producto complejo y la fase se restaura.
3. **¿Qué significa que los parámetros sean reales?** Son α y β , componentes reales de coeficientes complejos; no implica coeficientes GMP restringidos al eje real.
4. **¿Por qué el independiente tiene más libertad?** Sustituye la matriz rotacional de dos grados por una transformación I/Q general de cuatro grados.
5. **¿Dónde entra exactamente PN?** En $r(n)$, aplicado a toda fila de U y a y , antes del ajuste, y deshecho con $r^*(n)$ tras predecir.
6. **¿Podría separarse I/Q sin PN?** Sí; por eso existe el control Independent I/Q without PN.
7. **¿Qué demuestra ese control?** En esta captura, elegir coordenadas PN mejora 0.723 dB al modelo independiente sin PN; no demuestra universalidad.
8. **¿Por qué DOMP?** Para reducir una población correlacionada mediante selección y doble ortogonalización reproducibles.
9. **¿Por qué no OMP?** El estudio final congeló DOMP como único selector para evitar mezclar algoritmos y porque sus tests quedaron validados.
10. **¿DOMP entra en FLOPs de inferencia?** No. Solo identifica soporte; inferencia usa las columnas seleccionadas.
11. **¿Por qué 100 coeficientes GMP son 200 parámetros?** Cada complejo $h = \alpha + j\beta$ contiene dos escalares reales libres.
12. **¿Por qué un GMP parameter-matched?** Para comprobar si la mejora se explica solo por más parámetros frente al baseline de 200.

13. **¿Por qué la PNNN empieza con 1046 y acaba con 358?** N12 se entrena ancha y el pruning conserva 344 pesos más 14 biases.
14. **¿Es completamente justa la comparación?** Es mucho más controlada en identificación, dominio evaluado, métrica y parámetros activos; aún difieren optimización y capacidad inicial. La evaluación completa contiene identificación y no es un hold-out.
15. **¿Por qué N12 sparse mejora a H4 dense?** Puede conservar un patrón distribuido dentro de una arquitectura ancha; aquí mejora 2.267 dB, sin garantía.
16. **¿Por qué no aparece la PNNN histórica de 1200 parámetros?** No cumple el mismo presupuesto ni el mismo split; serviría como referencia, no comparación principal.
17. **¿Cómo se cuentan los FLOPs de la red sparse?** La cifra principal omite pesos exactamente nulos; ejecutar las matrices completas eleva el coste de 876 a 2252 FLOPs/muestra.
18. **¿La red sparse será realmente más rápida?** No necesariamente: hace falta kernel sparse, y latencia depende de hardware, memoria y ELU.
19. **¿Contribución defendible?** La derivación PN-GMP coupled, su extensión independent con controles justos, y la comparación de parámetros/FLOPs.
20. **¿Qué no debemos afirmar?** “Primero”, superioridad universal o hardware, menor energía/latencia, o robustez multi-PA no medida.

18. Guion oral de cinco minutos

Problema (40 s). “Queremos modelar una señal compleja con memoria bajo pocos datos de identificación y comparar GMP y PNNN sin mezclar splits ni presupuestos. Usamos el mismo 4 % para ajustar todos los modelos y evaluamos todos sobre la misma señal completa, que incluye ese 4 %.”

Idea (55 s). “Rotamos cada fila del GMP con la fase conjugada de la muestra actual. La forma coupled convierte el producto complejo en una matriz real I/Q con dos parámetros por coeficiente y es exactamente equivalente. Después liberamos el acoplamiento: I y Q tienen coeficientes independientes en ese marco.”

Controles (50 s). “DOMP selecciona soporte solo en identificación. El GMP matched controla el número de parámetros; I/Q sin PN controla las coordenadas; PN-IQ reducido controla el presupuesto de 200. Coupled reutiliza exactamente el soporte GMP.”

PNNN (45 s). “Comparamos H4 dense, N12 dense y N12 sparse. La sparse parte de 1046 parámetros y, con pruning global, biases protegidos y fine-tuning, termina con 358 activos, igual que PN-IQ.”

Resultados (55 s). “Sobre la señal completa, Independent PN-IQ alcanza -38.534 dB; GMP matched, -38.170; N12 sparse, -35.900. PN aporta 0.723 dB frente al control sin PN. N12 sparse mejora 2.267 dB a H4, pero pierde 0.731 frente a N12 dense. Los tres modelos principales tienen 358 parámetros.”

Coste y cierre (55 s). “PN-IQ usa 1062 FLOPs/muestra. N12 sparse usa 876 si se omiten pesos cero o 2252 si se ejecutan matrices completas, más 12 ELU. Por tanto, PN-IQ gana NMSE en esta captura y la red gana el conteo aritmético bajo ejecución sparse. La evaluación completa incluye identificación; faltan hold-out multi-captura, múltiples seeds y validación hardware.”

Versión de 30 segundos. “Reformulamos un GMP en coordenadas phase-normalized. La variante coupled es algebraicamente el mismo GMP; al liberar I/Q obtenemos una clase más flexible. Con 358 parámetros, Independent PN-IQ logra -38.534 dB y PNNN N12 sparse -35.900 dB sobre la señal completa. PN-IQ cuesta 1062 FLOPs; la red sparse, 876 si se omiten ceros y 2252 con matrices completas, más 12 ELU. Es un resultado de una captura cuya evaluación incluye identificación, no una victoria universal.”

19. Resumen de una página para estudiar

Fórmulas. $r = x^*/|x|$ ($r = 1$ si $x = 0$); $U_{PN} = rU$; $y_{PN} = ry$; $\hat{y} = r^*\hat{y}_{PN}$. $U_R = [U_I, -U_Q; U_Q, U_I]$. $\text{NMSE}_{dB} = 10 \log_{10}(\|y - \hat{y}\|^2/\|y\|^2)$. $P(H) = H(D+3) + 2$, con $D = 84$.

Concepto	Mensaje memorizable
Coupled	Dos parámetros por regresor; estructura rotacional; GMP exacto; error relativo $1,320 \times 10^{-11}$.
Independent	Coefficientes I/Q libres; más general, no equivalente; puede mejorar y sobreajustar.
Papel de PN	Marco de fase de la muestra actual; importa al romper acoplamiento; no rotar cada tap con su fase.
DOMP	Selección en identificación, doble ortogonalización, no entra en inferencia.
Protocolo	Identificación 19,661 (4.00004 %); selección interna 16,711/2,950; señal completa 491,520 e incluye identificación.
Parámetros	GMP-100=200; PN-IQ=358; GMP matched=358; H4=350; N12 sparse=358 activos.
Full-signal NMSE	PN-IQ -38,534; GMP matched -38,170; N12 sparse -35,900; H4 -33,633 dB.
FLOPs/muestra	PN-IQ 1062; GMP matched 1899; H4 876; N12 sparse 876 omitiendo ceros/2252 con matrices completas.
Special ops	PN-IQ 26; N12 sparse 54, incluidas 12 ELU/exp de peor caso.
Sí puedo decir	Equivalencia coupled; mejora observada al liberar I/Q; controles parameter-matched y sin PN; coste analítico explícito.
No debo decir	Primero absoluto; mejor hardware; menor energía/latencia; generaliza a cualquier PA; sparse ideal garantizado.

Tres diferencias clave: Independent PN-IQ supera 0.363 dB al GMP matched y 2.634 dB a N12 sparse; N12 sparse supera 2.267 dB a H4. Omitiendo pesos nulos, N12 requiere 186 FLOPs menos que PN-IQ, pero con matrices completas requiere 1190 más.

Respuesta final si preguntan “¿quién gana?” “En NMSE de esta captura gana Independent PN-IQ. En FLOPs/muestra gana la PNNN sparse si la implementación omite ceros; si ejecuta matrices completas, su coste sube a 2252. Sin plataforma ni métrica prioritaria no hay ganador absoluto.”

Fuentes congeladas

Las tablas proceden de `comparison_results.csv`, `parameter_summary.csv`, `complexity_flops.csv` y `selected_hyperparameters.csv`. La partición y configuración se verifican en `split_indices.mat` y `comparison_config.mat`; soportes en `domp_supports.mat`; predicciones finales en `full_signal_predictions.mat`. Todos pertenecen a `results/full_signal_domp_comparison/20260714_102201`.

Referencia DOMP.

- [1] J. A. Becerra et al., “A Doubly Orthogonal Matching Pursuit Algorithm for Sparse Predistortion of Power Amplifiers.” Referencia DOMP indicada en el proyecto; los artefactos locales no incluyen metadatos bibliográficos completos.